RESEARCH NOTE

# TIC

Transport Instability Coordinates

## 왜 '큰 업데이트'가 아니라
## '가능한 다음 변화의 분포'를 측정했는가

발상의 출발점 · 실험 설계의 논리 · 연구 가치 · 스케일 한계 · 다음 실험 · 연구를 하며 배운 점

PATH DEPENDENCE | FROZEN COUNTERFACTUAL | SOURCE x GAIN

CORE THESIS

Training state를 한 개의 point로만 보지 않고,
그 state가 지금 만들어낼 수 있는 conditional transition ensemble로 읽는다.

Scientific object: $T_t = Law[\, f(\theta_t + U_t) - f(\theta_t) \mid F_t \,]$

Research rationale / Korean edition

01 / ORIGIN

# 같은 설계도로 시작해도, 같은 모델로 남지 않는다

발상의 출발점은 거창한 외부 이론이 아니라 random initialization과 stochastic training이 만드는 path dependence였다.

MICRO DIFFERENCE → DIFFERENT HISTORY → DIFFERENT LOCAL GEOMETRY




같은 초기화 분포

**실제 random matrix realization은 다름**

### 1. 작은 차이는 학습 history를 바꾼다

Attention head들이 같은 분포에서 초기화돼도 실제 행렬은 서로 다르다. 그 미세한 방향 차이가 activation과 gradient를 바꾸고, optimizer state와 representation geometry의 차이로 누적될 수 있다. 그래서 같은 architecture·LR·비슷한 loss만으로 "현재 이 checkpoint가 무엇에 민감한지"를 알 수 없다.

### 2. 그래서 평균적인 모델보다 현재 checkpoint를 본다

Spike의 원인이 random initialization이라고 주장하는 것이 아니다. 핵심은 긴 stochastic history를 지나온 particular checkpoint가 이미 고유한 local sensitivity를 갖고 있을 수 있다는 점이다. 따라서 다음 update의 크기뿐 아니라, 지금 이 모델이 그 update를 어떻게 받아들이는지를 측정해야 한다.

CONCEPTUAL INFLUENCE - FEP, NOT A FORMAL DERIVATION

FEP를 공부하며 얻은 유용한 직관은 "state를 현재 값 하나로만 보지 말고, 그 state가 어떤 관측·변화를 생성할 수 있는지까지 보자"는 것이었다. 이를 training에 그대로 적용한 것은 아니다. 더 구체적인 질문으로 바꿨다: "수많은 stochastic history를 거쳐 여기까지 온 이 checkpoint가, 지금 가능한 다음 optimizer updates를 어떤 representation changes로 바꾸는가?"

**핵심 연결:** static state description → state as a generator of possible next transitions

# 시간을 멈추고, 현재 상태의 ensemble을 만든다

Ghost update는 augmentation이 아니라, 현재 checkpoint의 반응을 같은 state 아래 반복해서 보기 위한 local counterfactual instrument다.

PAST WINDOW

t-3 t-2 t-1 t



각 점은 서로 다른 training state

FROZEN ENSEMBLE



한 state에서 가능한 여러 next step

## 논문 원본 measurement schematic

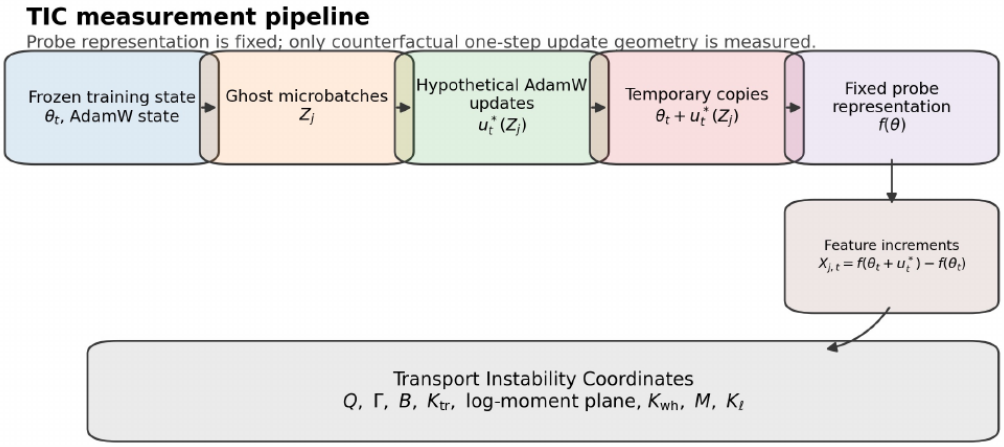



Figure - TIC measurement pipeline (repository paper figure)

THE OBJECT

$$T_t = \mathrm{Law}[\, f(\theta_t + U_t) - f(\theta_t) \mid F_t \,]$$

한 번의 update가 아니라 "현재 optimizer state가 유도하는 representation transition의 조건부 분포"를 측정한다. Alarm score는 이 분포를 압축한 downstream use일 뿐이다.

### 왜 freeze하는가

실제 trajectory를 여러 번 진행하면 측정하는 동안 모델과 optimizer state가 함께 변한다. Freeze는 동일한 현재 state 아래에서 minibatch randomness가 만드는 local law를 비교하기 위한 장치다.

# “큰 update”와 “큰 functional change”를 분리했다

같은 parameter-space update statistics라도 어느 방향으로 들어가느냐에 따라 representation consequence는 달라질 수 있다.

INTUITION

같은 크기의 힘 × 현재 구조의 민감도 → 실제 움직임

optimizer source × network sensitivity / Jacobian → representation transition

SOURCE-GAIN DECOMPOSITION

$$Q_t = q_t \times g_{Q,t} \qquad \Gamma_t = \gamma_t \times g_{\Gamma,t}$$

source power × representation gain — source covariance × representation gain

## Matched-source intervention

주장이 맞다면 source를 고정하고 exposure만 바꿔도 결과가 달라져야 한다. 그래서 parameter-space mean energy, covariance trace, total second moment, noise ratio를 맞추고 update 방향만 high-Jacobian / low-Jacobian direction으로 바꿨다.

LOW-J DIRECTION

same source statistics

representation gain 1×

HIGH-J DIRECTION

same source statistics

representation gain 81.2×

### SAME UPDATE POWER ≠ SAME FUNCTIONAL CONSEQUENCE

Update norm은 source의 한 채널을 본다. TIC는 그 source가 현재 network geometry를 통과해 어떤 representation transition을 만드는지까지 본다.

# 실험은 성능을 쌓기보다 대체 설명을 하나씩 제거했다

각 실험은 다른 반론을 겨냥한다. 이 순서가 연구의 논리를 만든다.

01 **UPDATE NORM이면 충분한가?**

source magnitude만으로 설명 가능 — Matched source / different Jacobian

81× gain difference

02 **Frozen geometry가 static artifact인가?**

현재 측정이 미래와 무관 — Paired optimizer branches

ρ=0.942 rep / 0.851 loss

03 **LR/time schedule을 읽은 것뿐인가?**

stress shortcut / post-hoc tuning — Dense Transformer + baselines + frozen split

AUPRC 0.542 log-moment

04 **다른 seed/scale에서도 남는가?**

seed-specific artifact / small-model only — Frozen extra seeds + PolyPythias anatomy

0.570 AUPRC / 410M anatomy

## Causal spike-label construction

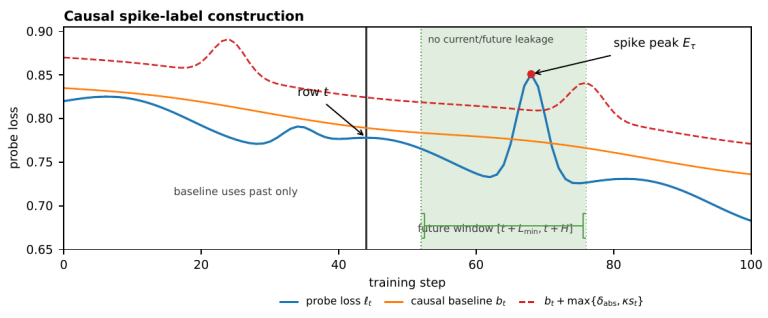



Figure - past-only baseline, future window, and no-current/future-leakage labeling

# 가장 중요한 결과는 “모든 feature가 이겼다”가 아니다

이론이 예측한 정보 보존 순서가 나타났고, log-moment plane이 대부분의 predictive value를 이미 담고 있었다.

## 실제 논문 figure로 보는 핵심 evidence

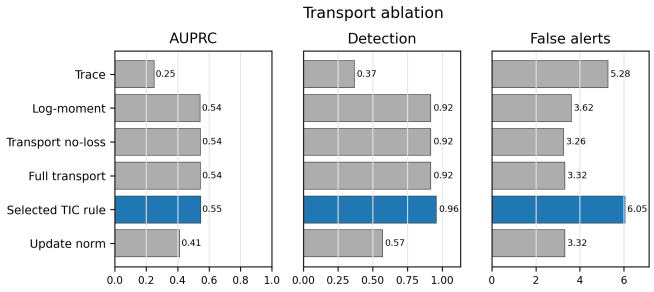



Figure - held-out transport ablation: AUPRC / detection / false alerts

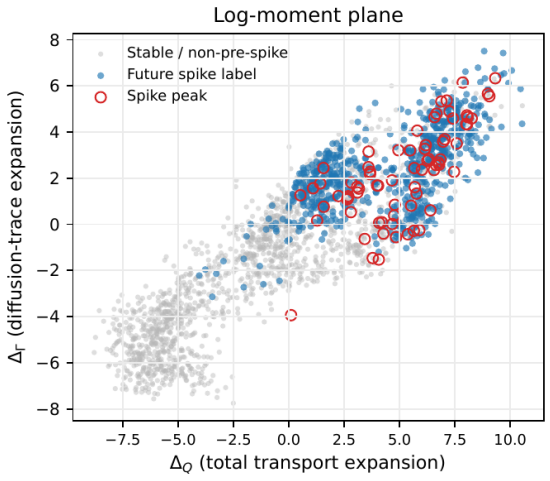



Figure - future spike labels occupy the high-ΔQ, high-ΔΓ region

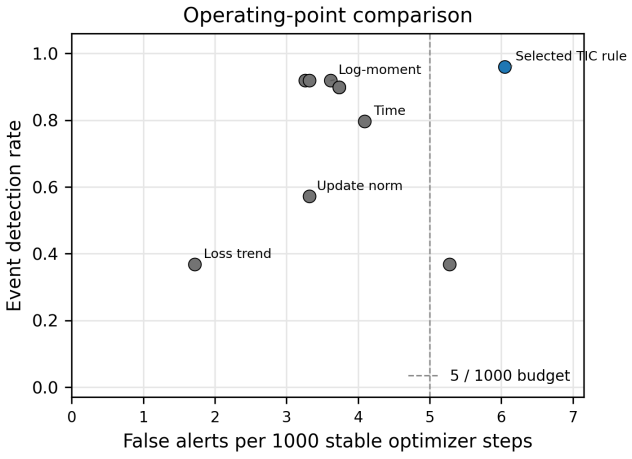



Figure - operating-point trade-off on held-out data

READING THE FIGURES

핵심은 “feature를 많이 넣어 성능을 올렸다”가 아니다. Trace ratio처럼 공동 팽창을 지우는 압축은 약해지고, ΔQ와 ΔΓ를 보존한 log-moment plane이 dominant signal을 유지한다. 예측 성능은 이 measurement geometry가 실제 downstream information을 갖는지 확인하는 검증이다.

06 / RESEARCH VALUE

# 가치는 alarm score가 아니라 measurement layer에 있다

Loss spike prediction은 이 geometry가 실제로 정보를 갖는지 확인한 첫 downstream task다.

### MEASUREMENT

Parameter-space telemetry를 넘어서 optimizer source와 network gain의 composition을 본다. "얼마나 크게 움직였나"에서 "현재 모델이 그 움직임을 얼마나 크게 functional change로 바꾸는가"로 질문을 이동시킨다.

### MECHANISM INTERFACE

Adam preconditioner, weight-norm criticality, edge-of-stability, spectral alignment처럼 서로 다른 이야기를 J, update moments, feedback operator가 만나는 공통 인터페이스로 비교할 수 있다.

### COUNTERFACTUAL USE

동일 checkpoint에서 optimizer를 비교하거나, layerwise anatomy를 보거나, 실제 step을 밟기 전에 intervention의 local consequence를 시험하는 measurement로 확장할 수 있다.

A DIAGNOSTIC IS NOT A MEASUREMENT UNTIL ITS COORDINATE DEPENDENCE IS KNOWN.

현재 trace coordinates는 orthogonal transform과 global rescaling을 포함한 conformal group CO(p)까지는 universal invariant지만, arbitrary GL(p) reparameterization에는 invariant하지 않다. Full matrix-anchor geometry는 이론적으로 가능하지만 현재 k=4, p=128 rowwise estimator에서는 covariance rank가 부족해 구현할 수 없다.

이 제한을 숨기지 않는 이유

"좋은 predictor"를 주장하는 것과 "좌표 선택에 어떤 의미로 독립적인 measurement"를 주장하는 것은 다르다. 이 연구는 후자의 경계까지 명시하려 했다.

BOUND OF CLAIM

Dense benchmark의 learning-rate ramp 때문에 C_t는 pure gain이 아니라 source + gain mixture다. 따라서 개별 spike의 원인을 C_t 하나로 attribution하거나, 다른 optimizer/architecture에 동일 성능이 난다고 일반화하지 않는다.

# 작은 스케일의 디메리트는 실제로 크다

핵심 derivation은 모델 크기에 의존하지 않지만, “대형 LLM에서도 같은 measurement가 필요한가?”라는 가장 중요한 외적 타당성 질문은 충분히 닫지 못했다.

## 현재 evidence ladder

- **Controlled MLP**
  source 고정 / gain intervention
- **Small Transformer**
  dense early-warning / frozen protocol
- **PolyPythias 410M**

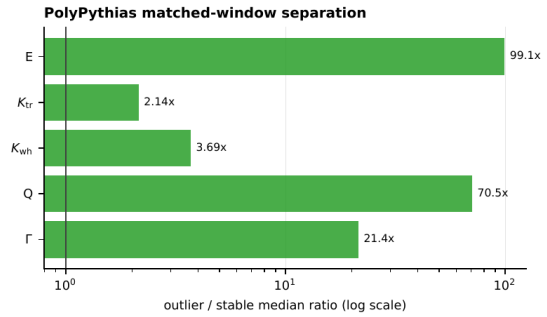



Figure - PolyPythias 410M matched-window separation (log scale)

### 스케일 때문에 남은 질문

- 자연 발생 LLM instability에서도 geometry가 먼저 변하는가?
- 어느 layer가 먼저 민감해지는가?
- geometry를 낮추는 intervention이 실제 spike를 막는가?
- 더 많은 ghost로 covariance geometry를 안정적으로 추정할 수 있는가?

OBJECTIVE TAKE

Compute가 더 컸다면 단순히 “더 큰 benchmark”를 돌리는 것이 아니라, 이 논문의 가장 큰 open question을 직접 검증할 수 있었다. 성공했다면 평가가 크게 올라갈 여지는 분명하지만, 큰 모델에서 결과가 유지된다는 보장은 없으므로 “GPU만 많았으면 자동으로 강한 논문”이라고 말할 수는 없다.

**핵심: scale은 novelty 자체보다 claim의 범위를 제한했다.**

# 장비 제약이 없었다면, 더 크게가 아니라 더 결정적으로

목표는 correlation을 하나 더 얻는 것이 아니라, transition geometry의 선행성과 intervention 가능성을 large-scale에서 동시에 확인하는 것이다.

## 1. Scale ladder




same measurement family / multiple seeds / natural + stressed regimes

### 2. Dense layerwise ghost ensemble

선택 layer마다 k=32-64+ ghost transitions. source/gain decomposition과 covariance geometry를 충분한 rank로 추정.

### 3. Pre-spike checkpoint branching

loss, gradient norm, update norm이 아직 정상인 checkpoint에서 optimizer intervention을 만들고 모든 branch에 동일한 future token sequence를 흘린다.

### 4. Causal success criterion

TIC geometry가 먼저 확장하고, geometry를 낮추는 intervention이 같은 미래 데이터에서 실제 spike까지 줄이면 “measurement → intervention” 연결이 생긴다.

**가장 강한 그림**

“기존 telemetry는 정상인데 TIC만 먼저 확장 → intervention으로 TIC를 낮춤 → 같은 미래 데이터에서 spike가 사라짐.” 이 패턴이 여러 1B-7B run에서 반복되면, TIC는 alarm feature가 아니라 training-instability measurement로 훨씬 강해진다.

# AI를 공부하면서 왜 직접 연구를 택했고, 무엇을 배웠는가

아래는 논문의 formal claim이 아니라, 이 프로젝트를 진행하며 형성된 개인적인 연구 방향에 대한 기록이다.

### 01 연구하면서 배우는 것이 가장 빨랐다

AI 공부를 시작하면서 강의나 논문을 따라가는 것보다, 직접 질문을 만들고 수식을 세우고 실험이 반례를 만드는 과정을 겪는 편이 훨씬 빠르게 배울 수 있다고 판단했다. TIC는 그 방식으로 만든 초기 연구 중 하나다.

### 02 원래도 toy-scale이었고, 실험 유실로 공개 evidence는 더 작아졌다

장비 제약 때문에 처음부터 대규모 pretraining study가 아니라 controlled MLP와 small Transformer 중심으로 설계했다. 여기에 작업 과정에서 실험 환경과 산출물이 한 차례 크게 유실되면서, 원래 계획했던 더 넓은 실험 범위를 재구성하지 못했고 재현 가능하게 공개할 수 있는 evidence는 더 toy-scale에 가까워졌다. 이 한계는 방법론의 가치로 포장하지 않고 그대로 인정한다.

### 03 Empirical AI research에서 compute는 "속도"가 아니라 "가능한 주장"을 제한한다

이 프로젝트를 통해 AI 연구는 다른 많은 분야보다 장비와 실험 인프라 의존도가 압도적으로 높다고 느꼈다. 더 많은 GPU는 단순히 같은 실험을 빨리 돌리는 자원이 아니라, scale ladder, 반복 seed, dense checkpoint, counterfactual branch처럼 어떤 가설을 믿을 만하게 검증할 수 있는지를 결정한다.

### 04 그래서 취업할 때까지는 theory-first에 더 무게를 두기로 했다

개인 연구 단계에서는 아이디어의 질과 별개로 compute 접근성이 scale, seed 반복, dense checkpoint, causal branch처럼 "어디까지 주장할 수 있는가"를 크게 좌우한다는 비대칭을 체감했다. 그래서 더 큰 장비에 안정적으로 접근할 수 있는 환경에 들어가기 전, 즉 취업할 때까지는 identifiability, invariance, causal structure처럼 수식과 논리로 먼저 좁힐 수 있는 theory-first 문제에 더 집중하려 한다.

# 이 프로젝트가 남긴 한 문장

한 trajectory의 관찰에서, 현재 state가 허용하는 counterfactual ensemble의 측정으로.

FROM

**“방금 update가 얼마나 컸나?”**

TO

**“지금 이 state가 어떤 다음 변화를 만들 수 있나?”**

## Repository package

GitHub bundle에는 final paper, LaTeX source, public code, fixed result archive, additional seed audit, validation 기록, provenance 기록이 포함되어 있다. 공개본의 수치와 재현 범위는 저장된 artifact를 기준으로 읽는 것이 안전하다.

SOURCE NOTES

- Primary manuscript: paper3(3).pdf - conditional transition law, source-gain decomposition, invariance, realized dynamics, controlled branches, dense benchmark, PolyPythias audit.
- GitHub bundle: README.md - public-facing protocol and metrics; docs/VALIDATION.md - packaging and test validation; docs/PROVENANCE.md - preserved artifacts and missing scope.
- Random-initialization/path-dependence is used here as a motivation for why a particular checkpoint may have idiosyncratic local sensitivity; the manuscript does not claim that initialization is the causal origin of spikes. FEP is conceptual inspiration only, not a formal derivation.

AUTHOR EPILOGUE

AI를 배우기 시작하며 직접 연구하는 것이 가장 빠른 학습법이라고 생각해 이 프로젝트를 시작했다. 원래도 compute-constrained toy scale이었고, 실험 환경 유실로 공개 evidence는 더 작아졌다. 그 과정에서 empirical AI research의 compute 접근성이 주장 가능한 범위 자체를 크게 제한하는 현실을 체감했다. 그래서 더 큰 실험 인프라에 안정적으로 접근할 수 있는 환경에 들어가기 전, 즉 취업할 때까지는 이론과 identifiability를 먼저 세우는 theory-first 연구에 더 무게를 두려 한다.